


# TinyML

## Introducción

Prof. Ernesto Sifuentes de la Hoya  
UACJ – Universidad Autónoma de Ciudad Juárez, Chih., México  
IIT – Instituto de Ingeniería y Tecnología  
Dpto. Ingeniería Eléctrica y Computación



Fuente: ilustración generada con IA (ChatGPT, OpenAI). Ernesto Sifuentes, 19 ago. 2026.

**Inteligencia artificial embebida: sistemas electrónicos con capacidades cognitivas.**

# Cuando pensamos en IA...



Solemos imaginar grandes modelos entrenados en centros de cómputo masivo.

- ❖ La IA moderna suele apoyarse en servidores, GPU y centros de datos de gran escala.



## Infraestructura masiva

servidores, GPU y almacenamiento



## Enfriamiento intensivo

control térmico para evitar fallas



## Gran consumo energético

cómputo + red + operación continua



## Huella de carbono

depende de la energía utilizada



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.



¿Podemos llevar parte de esa inteligencia a dispositivos pequeños y cercanos al sensor?

# IoT → AIoT → Edge AI → TinyML

Cómo se movió la inteligencia: de la nube al microcontrolador.



## Del centro de datos al microcontrolador



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

# La pregunta inicial

Ubiquemos dónde vive la inteligencia artificial.



## Nube

Entrena modelos grandes y procesa datos masivos.

## Borde

Decide cerca del sensor: gateway, cámara, PLC o PC industrial.

## TinyML


Ejecuta modelos compactos dentro de microcontroladores.

**Idea inicial:** No siempre necesitamos subir todo a la nube.

# ¿Qué es IoT?



El **Internet de las cosas (IoT)** es la red de objetos físicos —**dispositivos**, vehículos, edificios y otros elementos embebidos con electrónica, software, sensores y conectividad de red— que permite a estos objetos recopilar e intercambiar datos.




<https://www.logique.co.id/blog/en/2020/03/19/basic-principles-internet-things-iot/>

Un **dispositivo** es un equipo que debe comunicarse y puede también captar, almacenar o procesar datos, así como ejecutar acciones según la información recibida de las redes.

# ¿Qué es IoT?



## Arquitectura IoT compuesta por 3 capas principales




✓ **Capa 1 – Dispositivos:** sensores físicos conectados a equipos IoT.

✓ **Capa 2 – Edge:** recolección y procesamiento inicial de datos.

✓ **Capa 3 – Nube:** almacenamiento, aplicaciones móviles y web para clientes.

La nube ofrece visualización, análisis y exploración de los datos por parte de los usuarios finales.

# Arquitectura clásica del IoT



**Se producen 5 quintillones de bytes de datos al día gracias al IoT, pero solo se utiliza el 1%.**  
(Fuente: HBR/CISCO)

# El IoT y SDG



<https://globalgoals.org/es/>

## ► 2: Hambre cero:


En 2017, unos 821 millones de personas sufrían desnutrición. Para 2050, la producción anual de cereales y carne deberá aumentar significativamente para alimentar a 9.1 mil millones de personas.

## ► 13 y 15: Acción por el clima y vida de ecosistemas terrestres:

Las emisiones de gases de efecto invernadero hacen probable que la temperatura global supere 1.5°C este siglo. Las emisiones de CO<sub>2</sub> han aumentado casi un 50% desde 1990.

La combinación de **IoT** e **IA** optimiza siembra, riego y cadenas de suministro para producir más con menos y reducir el desperdicio, mientras monitorea emisiones, anticipa riesgos climáticos y alerta sobre deforestación para proteger los ecosistemas.

# ¿Por qué preocuparse por el IoT?




# ¿Por qué preocuparse por el IoT?




## History of the future

One to many to any: ICTs from happy few to the masses



Digital revolution: are we ready? | Mario Maniewicz, Chief, Infrastructure, Enabling environment and ICT applications, ITU/BDT




© Statista 2021

# ¿Por qué preocuparse por el IoT?



## Proyecto típico AIoT



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

Entrenamiento, procesamiento e inferencia se realizan en la nube.

## Problemas...

**B**andwidth Ancho de banda: capacidad de la red para **transportar datos por unidad de tiempo**.

**L**atency Latencia: **demora** entre capturar un dato y recibir la **respuesta/acción**.

**E**nergy Energía: **consumo eléctrico** del dispositivo (MCU, sensores y radio).

**R**eliability Confiabilidad: probabilidad de **funcionar correctamente y a tiempo** de forma sostenida.


**P**rivacy Privacidad: protección de **datos sensibles** frente a accesos o usos no autorizados.

La inteligencia permanece en la nube: más capacidad, mayor dependencia de la conexión.

# ¿Por qué preocuparse por el IoT?




## Bandwidth



<https://github.com/Mjrovai/UNIFEI-UESTI01-TinyML>

La red se satura porque los dispositivos envían **datos crudos** (video, audio, vibración) de forma **continua**. Resultado: alta latencia, pérdidas y costos de nube/red disparados.

## Latency




<https://github.com/Mjrovai/UNIFEI-UESTI01-TinyML>

**Demora** desde que se capta el dato hasta la **decisión/acción**. Incluye sensado + preprocesado + red + nube + actuación.

# ¿Por qué preocuparse por el IoT?




## Energy



<https://github.com/Mjrovai/UNIFEI-UESTI01-TinyML>

Consumo total del dispositivo (MCU + sensores + radio). Clave en nodos **a batería** o **energía cosechada**

## Reliability



<https://github.com/Mjrovai/UNIFEI-UESTI01-TinyML>

Probabilidad de que el sistema **funcione correctamente y a tiempo** ante fallas de red, equipo o software.

# ¿Por qué preocuparse por el IoT?



## Privacy




<https://github.com/Mjrovai/UNIFEI-UESTI01-TinyML>

Protección de **datos personales/sensibles** (audio, imagen, biométricos, ubicación) desde el dispositivo hasta la nube.

# IoT 2.0 – IA en el borde (Edge AI)



... Solución -> “Aplicar el aprendizaje automático en el borde (donde se generan los datos).”



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

El **dispositivo** en el borde procesa los datos localmente y puede tomar decisiones en tiempo real, reduciendo la dependencia de la nube.

Cuando el **IoT se combina con la IA**: surge el aprendizaje de máquina embebido (TinyML).


# IA en el borde (Edge AI)

La inferencia se ejecuta en la periferia de la red.



- ✓ Reduce tráfico hacia la nube.
- ✓ Permite respuestas más rápidas.
- ✓ Mantiene más datos sensibles dentro del sistema local.
- ✓ Puede funcionar aun con conectividad intermitente.
- ✓ En el borde hay **recursos limitados**, pero...
  - ❖ **Menor consumo de ancho de banda.**
  - ❖ **Menor latencia** (respuestas más rápidas).
  - ❖ **Mayor privacidad de los datos.**

**La nube no desaparece:** se complementa con el borde.



<https://docs.edgeimpulse.com/knowledge/courses/edge-ai-fundamentals/intro-to-edge-ai>

**El borde incluye:** gateways, routers, PCs industriales, teléfonos y MCUs.

# IA en el borde (Edge AI)



## Ventajas del borde (BLERP)

**B**andwidth ↓ (se envían resultados, no datos crudos).

**L**atency ↓ (respuesta casi inmediata).

**E**nergy ↑ eficiencia (menos transmisión inalámbrica).

**R**eliability ↑ (funciona **sin** Internet).

**P**rivacy ↑ (datos crudos no salen del dispositivo).



# IA en el borde (Edge AI)



## Ventajas del borde (BLERP)

**Bandwidth** ↓ (se envían resultados, no datos crudos).

**Latency** ↓ (respuesta casi inmediata).

**Energy** ↑ eficiencia (menos transmisión inalámbrica).

**Reliability** ↑ (funciona **sin** Internet).


**Privacy** ↑ (datos crudos no salen del dispositivo).

## Limitaciones del borde

- ✓ **Recursos limitados** (menos cómputo que la nube).
- ✓ **Acceso remoto** más complejo (VPN/servicios extra).
- ✓ **Seguridad:** IoT con credenciales/puertos por defecto → riesgo.
- ✓ **Escalado:** requiere **hardware** adicional.



“La solución es **acercar el ML a la fuente de datos.**”



# Inteligencia humana

- ✓ Resolver problemas
- ✓ Alcanzar objetivos
- ✓ Analizar y razonar
- ✓ Comunicar, colaborar e influir
- ✓ Conciencia, Emociones, Intuición, Imaginación



# Inteligencia Artificial:

La capacidad de las máquinas para **simular** y mejorar la inteligencia (humana).

# Inteligencia Artificial (IA)



La IA integra algoritmos que permiten a las máquinas (computadoras):

1. **Percibir** su entorno mediante datos provenientes de sensores, imágenes, señales o dispositivos IoT.
2. **Aprender** a partir de esos datos para identificar patrones, relaciones y comportamientos.
3. **Resolver** problemas mediante modelos computacionales, reglas o técnicas de aprendizaje automático.
4. **Tomar decisiones** o generar respuestas apropiadas con base en la información disponible.

**Meta:** desarrollar sistemas capaces de realizar tareas que tradicionalmente requerían inteligencia humana.

# Aprendizaje de máquina (ML)




Es una rama de la IA que permite a las máquinas **aprender patrones a partir de datos**, sin ser programadas explícitamente para cada tarea.

1. **Entrenar** modelos usando datos históricos o experimentales.
2. **Identificar patrones** en señales, imágenes, mediciones o bases de datos.
3. **Predecir** valores, clases o comportamientos futuros.
4. **Mejorar su desempeño** conforme se dispone de más información.

**Meta:** construir modelos capaces de generalizar a partir de datos y tomar decisiones ante nuevos casos.

# Aprendizaje de máquina (ML)



**Data Science (Ciencia de Datos):** Disciplina que extrae conocimiento útil de datos para apoyar decisiones, usando estadística, programación y aprendizaje automático.

**IA (inteligencia artificial):** Cualquier técnica que permite a las computadoras imitar el comportamiento humano.

**ML (aprendizaje de máquina):** Capacita a las computadoras para aprender sin ser programadas explícitamente.


**DL (aprendizaje profundo):** Extraer patrones de los datos usando redes neuronales.

# Aprendizaje de máquina (ML)



¿Dónde se realiza?

- ❖ **CloudML:** ML en la nube (centros de datos).
- ❖ **EdgeML:** ML en el “borde” (dispositivos cercanos al usuario).
- ❖ **TinyML:** ML en microcontroladores/wearables de ultra bajo consumo.



<https://github.com/Mjrovai/UNIFEI-IESTI01-TinyML>

“La solución es **acercar el ML a la fuente de datos.**”

**TinyML** es el **EdgeML** más restringido en recursos. Entrenamiento e inferencia pueden combinarse (p. ej., entrenar en la nube e inferir en el borde).

# Aplicaciones del ML

# Detección de objetos


## Análisis de fotos

Procesamiento de imágenes estáticas para identificar objetos, personas y escenas.




## Procesamiento de video en vivo

## Detección y seguimiento de objetos en tiempo real en transmisiones de video.



[https://a2r-lab.org/files/CS249\\_F20\\_Slides.pdf](https://a2r-lab.org/files/CS249_F20_Slides.pdf)

# Aplicaciones del ML



<https://swisscognitive.ch/2021/03/18/applications-of-machine-learning/>

# Aplicaciones del ML

## Estimación de postura

Determinar posiciones y movimientos del cuerpo humano.



<https://github.com/Mjrovai/UNIFEI-IESTI01-TinyML>


# Aplicaciones del ML




## Clasificación de imágenes

Uso de sensores de cámara para reconocimiento visual.

| [PREDICTION] | [Prob] |
|--------------|--------|
| Egyptian cat | : 64%  |
| tabby        | : 14%  |
| bucket       | : 3%   |




| [PREDICTION]       | [Prob] |
|--------------------|--------|
| Labrador retriever | : 83%  |
| golden retriever   | : 13%  |
| bloodhound         | : 6%   |



| [PREDICTION]    | [Prob] |
|-----------------|--------|
| German shepherd | : 68%  |
| dhole           | : 16%  |
| malinois        | : 7%   |




<https://github.com/Mjrovai/UNIFEI-TEST01-TinyML>



¿Qué es  
TinyML?

# TinyML




**IA en el Borde (o ML en el Borde)** es ejecutar inteligencia artificial directamente en el dispositivo, cerca del sensor, sin depender de la nube.

**TinyML** consiste en ejecutar modelos de aprendizaje de máquina en microcontroladores de bajo consumo para analizar localmente datos de sensores.

# TinyML



**Def 1:** Conjunto de tecnologías que combina el aprendizaje automático y los sistemas embebidos para habilitar aplicaciones inteligentes en dispositivos de extremadamente bajo consumo.



[Unlocking Embedded Machine Learning with TinyML – Cardinal Peak](#)

## Ultra bajo consumo de energía

Consumo de energía de milivatios para dispositivos alimentados por batería.

## Memoria minúscula

Restricciones de kilobytes de RAM y memoria flash.

## Tiempo real

Inferencia inmediata sin conectividad a la nube.

# TinyML



Es una extensión del ML orientada a ejecutar modelos en dispositivos pequeños, de bajo consumo y con recursos limitados, como microcontroladores, sensores inteligentes y nodos IoT.

1. **Procesar** datos directamente en el dispositivo.
2. **Inferir** patrones o eventos sin depender siempre de la nube.
3. **Reducir** el consumo de energía, latencia y transmisión de datos.
4. **Habilitar** aplicaciones inteligentes en sensores, wearables y sistemas embebidos.


**Meta:** llevar la inteligencia artificial al borde del sistema, cerca del sensor y en tiempo real.

# TinyML






## TinyML se apoya en la integración de:

- ✓ **Hardware:** microcontroladores (e.j. Nano 33 BLE Sense o el ESP32).
- ✓ **Algoritmos:** modelos optimizados mediante técnicas como cuantización, poda o distilación.
- ✓ **Herramientas** de desarrollo: como TensorFlow Lite for Microcontrollers, Edge Impulse o CMSIS-NN.
- ✓ **Aplicaciones** locales: sistemas que funcionan incluso sin conexión a Internet, mejorando la privacidad y reduciendo la latencia.



<https://www.cardinalpeak.com/blog/harnessing-tinyml-to-revolutionize-iot-development>

# ¿Qué caracteriza a TinyML?




<https://datascientest.com/es/tinymml-todo-sobre>




TensorFlow Lite


# TinyML: Flujo de trabajo/Software



# TinyML: Hardware



|                          | Raspberry Pico (W)       | Arduino Nano Sense | ESP 32                 | Seeed XIAO Sense / ESP32S3                   | Arduino Pro                |
|--------------------------|--------------------------|--------------------|------------------------|----------------------------------------------|----------------------------|
| <b>32Bits CPU</b>        | Dual-core Arm Cortex-M0+ | Arm Cortex-M4F     | Xtensa LX6 Dual Core   | Arm Cortex-M4F (BLE)<br>Xtensa LX7 Dual Core | Dual Core Arm Cortex M7/M4 |
| <b>CLOCK</b>             | 133MHz                   | 64MHz              | 240MHz                 | 64 / 240MHz                                  | 480/240MHz                 |
| <b>RAM</b>               | 264KB                    | 256KB              | 520KB (part available) | 256KB / 8MB                                  | 1MB                        |
| <b>ROM</b>               | 2MB                      | 1MB                | 2MB                    | 2MB / 8MB                                    | 2MB                        |
| <b>Radio</b>             | (Yes for W)              | BLE                | BLE/WiFi               | BLE / WiFi (ESP32S3)                         | BLE/WiFi                   |
| <b>Sensors</b>           | No                       | Yes                | No                     | Yes (Sense)                                  | Yes (Nicla)                |
| <b>Bat. Power Manag.</b> | No                       | No                 | No                     | Yes                                          | Yes                        |
| <b>Price</b>             | \$                       | \$\$\$             | \$                     | \$\$                                         | \$\$\$\$\$                 |



# TinyML: datos de sensores



Los puntos finales de inteligencia están equipados con numerosos sensores que generan flujos de datos continuos.

## Sensores de movimiento

giroscopio, radar, magnetómetro, acelerómetro

## Sensores acústicos

ultrasónicos, micrófonos, geófonos, vibrómetros

## Sensores táctiles

pantallas táctiles capacitivas, IR

## Sensores de imagen

imágenes térmicas, ópticas

## Biométricos

huella dactilar, sensores de ritmo cardíaco

## Ambientales

temperatura, humedad, presión, sensores IR



# TinyML: aplicaciones



## Hogar inteligente



### Control climático inteligente

Aprendiendo las preferencias del usuario y optimizando el consumo de energía.



### Seguridad en el borde

Detección de amenazas en tiempo real sin dependencia de la nube.



### Control de voz privado

Reconocimiento de voz local preservando la privacidad.

# TinyML: aplicaciones

## Cuidado de la salud



### Monitorización continua

Dispositivos wearables que rastrean signos vitales con detección de anomalías impulsada por IA.



### Adherencia a la medicación

Dispensadores de pastillas inteligentes que aseguran la correcta sincronización y dosificación de la medicación.



### Sistemas de alerta temprana

Modelos predictivos que identifican riesgos para la salud antes de que aparezcan los síntomas.



### Respuesta a emergencias

Sistemas automáticos de detección de caídas y alerta de emergencia.

# TinyML: aplicaciones

## Industria



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

### Mantenimiento predictivo

Modelos de ML predicen fallas de equipos antes de que ocurran, reduciendo el tiempo de inactividad y los costos de mantenimiento.

- ❖ Análisis de vibraciones
- ❖ Monitoreo de temperatura
- ❖ Detección de firmas acústicas



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

### Control de calidad

Detección de defectos en tiempo real utilizando visión por computadora y fusión de sensores en la línea de producción.

- ❖ Inspección visual
- ❖ Precisión dimensional
- ❖ Evaluación de la calidad de la superficie

# TinyML: aplicaciones

## Agricultura



### Salud de cultivos

Sensores potenciados por IA detectan enfermedades de plantas, deficiencias de nutrientes y plagas tempranamente.



### Riego de precisión

Sistemas de riego inteligentes optimizan el uso del agua basándose en la humedad del suelo y las predicciones meteorológicas.



### Análisis de microclimas

Estaciones meteorológicas locales proporcionan datos ambientales para decisiones agrícolas.

# TinyML: aplicaciones

## Automoción



### Monitorización del conductor

Detección de fatiga y distracción mediante cámaras y fusión de sensores.



### Optimización del motor

Ajuste del rendimiento en tiempo real basado en las condiciones y patrones de conducción.



### Estacionamiento autónomo

Detección de objetos y planificación de rutas basada para asistencia al estacionamiento.


# TinyML: aplicaciones

## Monitoreo ambiental



### Calidad del aire

Detección y clasificación en tiempo real de contaminantes en entornos urbanos.



### Calidad del agua

Monitoreo continuo de la contaminación del agua y la salud del ecosistema.



### Contaminación acústica

Monitoreo acústico y clasificación de fuentes de ruido urbano.


# TinyML: aplicaciones

## Deportes y fitness



### Análisis de rendimiento

Corrección de forma y mejora de técnica en tiempo real.



### Inteligencia en equipamiento

Equipo deportivo inteligente que proporciona retroalimentación instantánea.



### Prevención de lesiones

Análisis biomecánico para prevenir lesiones deportivas.

# TinyML: implicaciones



## Beneficios de privacidad y seguridad

### Ventajas de privacidad

- ✓ Procesamiento de datos en la fuente.
- ✓ No se requiere transmisión a la nube.
- ✓ Control del usuario sobre los datos personales.
- ✓ Reducción de la exposición a filtraciones de datos.


### Beneficios de seguridad

- ✓ Superficie de ataque reducida.
- ✓ Independencia de la red.
- ✓ Respuesta más rápida a amenazas.
- ✓ Capacidad de operación sin conexión.

# Consideraciones éticas




A medida que TinyML se vuelve omnipresente, debemos abordar las importantes implicaciones éticas de la implementación generalizada de la IA.



# ¿Qué hace realmente un sistema de IA?



Convierte datos en una decisión útil.



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

**IA aplicada no es “magia”: es una cadena de ingeniería.**

# El flujo básico del ML



El modelo aprende a partir de ejemplos y luego predice sobre datos nuevos.



# Etapa 1: IA en la nube

Grandes modelos, muchos datos y capacidad de cómputo concentrada.



**AIoT → Edge AI → TinyML**



- ❖ Entrenamiento con grandes bases de datos.
- ❖ Infraestructura escalable: servidores, GPUs y almacenamiento.
- ❖ Útil cuando la latencia y la conexión no son críticas.
- ❖ No siempre conviene para sensores que deben responder localmente.

Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

# ¿Por qué mover la IA cerca del sensor?

En ingeniería no basta con predecir: hay que responder a tiempo y con recursos limitados.

## Latencia

La decisión llega tarde si debe viajar a la nube.

## Conectividad

El sistema debe seguir funcionando aunque falle Internet.

## Datos

No siempre conviene transmitir señales crudas.

## Energía

Enviar datos puede costar más que procesarlos localmente.

## Privacidad

Algunas señales no deberían salir del dispositivo.

## Costo

Menos transmisión puede reducir infraestructura.

El objetivo no es **reemplazar la nube**; es decidir qué debe ocurrir localmente.

# Etapa 2: Edge AI

La inferencia se acerca al proceso físico.




Ejecutar modelos en equipos cercanos a los sensores: gateways, cámaras inteligentes, PCs industriales o dispositivos embebidos con mayor capacidad.

- ❖ Menor latencia que la nube.
- ❖ Más recursos que un microcontrolador.
- ❖ Adecuado para visión, monitoreo y control local.

Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

# Etapa 3: TinyML

Cuando el modelo vive dentro de un microcontrolador.



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.


## TinyML = inferencia local en MCU

- ❖ Modelos compactos.
- ❖ Memoria limitada.
- ❖ Bajo consumo.
- ❖ Respuesta local.

“La IA ya no está lejos del sensor.”

# Qué tiene que cambiar para llegar a TinyML

No se “baja” un modelo grande sin rediseñarlo.



Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

TinyML es ingeniería de compromisos.

## Reducir

Menos parámetros y menos operaciones.

## Cuantizar

Usar int8/int16 en lugar de float32 cuando sea posible.

## Validar

Comprobar si la reducción no destruye el desempeño.

## Medir

RAM, flash, latencia y estabilidad en hardware.

# De la nube a TinyML

IoT → AIoT → Edge AI → TinyML




En **TinyML** la pregunta central es: ¿qué modelo cabe y responde en el dispositivo?

# IoT → AIoT → Edge AI → TinyML



La IA dejó la nube y terminó dentro del microcontrolador..



A medida que la inteligencia se acerca al microcontrolador, el sistema gana autonomía, velocidad de respuesta y operación local.

Fuente: Imagen generada por IA con fines ilustrativos. Ernesto Sifuentes, 2026.

# IoT → AIoT → Edge AI → TinyML

La inteligencia se desplaza de la nube al borde y finalmente al microcontrolador.

## IA en la nube

Entrenamiento, almacenamiento y analítica



Modelos de IA    Datos históricos    Visualización y analítica

## Edge AI

Procesamiento en el borde

- ⚡ Menor latencia
- ⚙️ Más autonomía
- 📶 Menor tráfico a la nube



Sensor de presión

Sensor de caudal

Actuador (motor)

Temperatura    Humedad    Presión    Vibración    Otros

## TinyML en el microcontrolador

Inferencia local

- 🕒 Tiempo real
- 🌿 Bajo consumo
- 🧠 Operación local



Sensor (en el dispositivo)

Actuador (indicador)

1

**IA en la nube:**  
entrenamiento y analítica centralizada

2

**Edge AI:**  
despliegue cerca del proceso

3

**TinyML:**  
inferencia dentro del microcontrolador

# Referencias



1. UNIFEI. *IESTI01 TinyML – Machine Learning for Embedding Devices* [Lista de reproducción]. YouTube.  
<https://www.youtube.com/playlist?list=PLwmX8w17ZuqYg68Xg2Wgj3i89aehHJ0JV>
2. edX/Harvard. *Professional Certificate in Tiny Machine Learning (TinyML)*.  
<https://www.edx.org/search?q=tiny-machine-learning>
3. Coursera/Edge Impulse. *Introduction to Embedded Machine Learning*.  
<https://www.coursera.org/learn/introduction-to-embedded-machine-learning>
4. Coursera/Edge Impulse. *Computer Vision with Embedded Machine Learning*.  
<https://www.coursera.org/learn/computer-vision-with-embedded-machine-learning>
5. Chollet, F. (2017). *Deep Learning with Python*. Manning Publications.  
<https://www.manning.com/books/deep-learning-with-python>
6. Warden, P., & Situnayake, D. (2019). *TinyML: Machine learning with TensorFlow Lite on Arduino and ultra-low-power microcontrollers*. O'Reilly Media.  
<https://www.oreilly.com/library/view/tinyml/9798341642423/>
7. Iodice, G. M. (2022). *TinyML Cookbook: Combining embedded, edge, and cloud machine learning for real-world solutions*. Packt Publishing.  
Recuperado de <https://www.amazon.com/TinyML-Cookbook-learning-microcontrollers-real-world/dp/1837637369>
8. Situnayake, D., & Plunkett, J. (2022). *AI at the Edge: Solving real-world problems with embedded machine learning*. O'Reilly Media.  
Recuperado de <https://www.oreilly.com/library/view/ai-at-the/9781098120191/>

# Créditos y agradecimientos



Se agradece a los siguientes educadores e investigadores por compartir sus materiales de enseñanza:

- **Prof. Marcelo Rovai** – TinyML machine learning for embedding devices, UNIFEI
- **Prof. Vijay Janapa Reddi** – CS249r: Tiny machine learning, Harvard
- **Prof. Rahul Mangharam** – ESE3600: Tiny machine learning, University of Pennsylvania
- **Prof. Brian Plancher** – Harvard CS249r: Tiny machine learning, Barnard College, Columbia University
- **Shawn Hymel** – Edge Impulse
- **Pete Warden** – Google
- **Laurence Moroney** – Google
- **TinyMLedu Team** – TinyML Education Initiative

Materiales educativos proporcionados por TinyML4D (<https://tinymml.seas.harvard.edu/showAndTell>), iniciativa internacional dedicada a democratizar el acceso al aprendizaje de TinyML en todo el mundo.

# Declaración de uso de IA Generativa

- ❖ Este material fue elaborado con apoyo de herramientas de **inteligencia artificial generativa**.
- ❖ La IA se utilizó para apoyar la **organización y síntesis de contenidos**, redacción técnica, generación de ejemplos, figuras y recursos visuales.
- ❖ Todo el contenido fue **revisado, validado, seleccionado y adaptado por el instructor** antes de incorporarse.
- ❖ Las decisiones técnicas, la secuencia didáctica, los criterios de evaluación y la selección final de los recursos son responsabilidad del instructor.

**Herramienta principal utilizada:** ChatGPT (OpenAI).



La IAG es un apoyo para aprender mejor, no un atajo para dejar de pensar.