


Ciclo de vida del Machine Learning y TinyML

Prof. Ernesto Sifuentes de la Hoya
UACJ – Universidad Autónoma de Ciudad Juárez, Chih., México
IIT – Instituto de Ingeniería y Tecnología
Dpto. Ingeniería Eléctrica y Computación




Fuente: ilustración generada con IA (ChatGPT, OpenAI). Ernesto Sifuentes, 19 ago. 2025.

IA embebida: sistemas electrónicos con capacidades cognitivas.

Ciclo de vida de Machine Learning

Parte 1: Del dato crudo a los datos listos para ML




Estas etapas suelen repetirse hasta obtener datos confiables.



La calidad del modelo depende en gran medida de la calidad de los datos.

Ciclo de vida de Machine Learning

Parte 2: Del entrenamiento al despliegue del sistema



Un sistema de ML útil no termina al entrenarse: debe evaluarse, desplegarse y mantenerse.

División del dataset: tips básicos

Cómo separar los datos para entrenar, ajustar y evaluar un modelo con confianza

pasos para una división efectiva



Ejemplo de split del dataset



¡Atención a la fuga de datos!

Usar información del conjunto de prueba (explícita o implícitamente) durante el entrenamiento produce métricas engañosas y modelos que no generalizan en la realidad.






Una buena división del dataset mejora la generalización y hace más confiable la evaluación del modelo.

Preparación de datos y validación del modelo

Ejemplos básicos de limpieza, selección de características y validación antes de usar un modelo


pipeline práctico



La validación confirma si el modelo generaliza bien después de una preparación correcta de los datos.

Ciclo de vida de TinyML




Del sensor al modelo embebido en dispositivos de bajo consumo



TinyML lleva el modelo al dispositivo: menor latencia, menor consumo y mayor autonomía.

Pipeline completo de TinyML

Desde la adquisición de señales hasta la validación del modelo



Un buen pipeline de TinyML equilibra desempeño, memoria, latencia y consumo energético.

Conclusiones



Machine Learning

- ❖ Machine Learning permite aprender patrones a partir de datos.
- ❖ La regresión predice valores; la clasificación asigna clases.
- ❖ La calidad del dataset influye directamente en el desempeño.
- ❖ La preparación de datos reduce errores y mejora la generalización.
- ❖ La división en entrenamiento, validación y prueba evita evaluaciones sesgadas.
- ❖ Las métricas permiten verificar si el modelo realmente aprende.
- ❖ Un buen modelo requiere iteración: preparar, entrenar, validar y mejorar.

Conclusiones



TinyML

- ❖ TinyML lleva el modelo al microcontrolador.
- ❖ La calidad de los datos define el desempeño.
- ❖ El preprocesamiento convierte señales en información útil.
- ❖ La división del dataset evita resultados engañosos.
- ❖ La optimización equilibra precisión, memoria, latencia y energía.
- ❖ La validación también debe realizarse en el dispositivo real.
- ❖ El pipeline es iterativo: medir, ajustar y mejorar.